Итоговый отчет по ML-кейсу Цифриум

Прогноз риска отчисления и интерпретируемые паттерны поведения студентов LMS

Команда «Три сигма»

2026-04-21

1. Краткий итог

Цель кейса: по LMS-данным построить ML-прототип, который заранее выявляет студентов с риском отчисления, объясняет причины риска и помогает тьюторам/методистам выбрать действие до того, как студент фактически перестал учиться.

Главный результат: собран рабочий прототип “Светофор” на уровне `user–course` (одна строка = один студент на конкретном курсе/модуле). “Светофор” классифицирует всех учеников каждого модуля на красную группу (высокий риск), жёлтую (средний риск) и зелёную (низкий риск). На экваторе модуля 3 модель обработала 1407 активных студентов и выделила 211 студентов красной зоны, то есть 15% потока с максимальным приоритетом для тьюторов.

Основной ход работы:

1. Сначала была выбрана гранулярность `user–course` в ноутбуке granularity_selection.ipynb: один студент в одном модуле/курсе. Затем в ноутбуке heuristics_status_deducing.ipynb собрана рабочая population-таблица со статусами по M1-M4, фактическим таргетом там, где он есть, и эвристическим таргетом там, где фактического статуса нет.
2. Затем в основном ноутбуке Tri_sigma_final_research.ipynb была собрана базовая витрина признаков: агрегаты из LMS-логов по действиям, отве-

там, просмотрам, тренингам, доступам и структуре курса. Эта витрина нужна как полная user-course база для анализа и контроля качества признаков.

3. Отдельно была собрана temporal-витрина с отсечением по времени: 33604 строки, по 4 snapshot-среза на каждый `user–course`. Срезы: 7-й, 14-й, 21-й день и `midpoint` (экватор модуля). В каждый снимок попадают только события, произошедшие до этого момента. Это защищает модель от утечки данных, когда в признаки случайно попадает будущая информация.
4. На подготовленных признаках проведен анализ связей: Spearman-корреляции, Mutual Information / MI (взаимная информация для поиска нелинейных связей) и Permutation Importance (оценка важности признака через перемешивание его значений).
5. Для прогноза риска использована Random Survival Forest (RSF): модель ранжирует студентов по риску, строит кривые выживаемости и дает риск-скор для “Светофора”. Итоговая метрика RSF: C-index = 0.7662 ± 0.0242. Переносимость проверена через Out-of-Time / OOT-валидацию: обучение на M2, тест на M3, C-index = 0.7636.
6. Для классификационной проверки дополнительно использован CatBoost: на внутренней проверке M1+M2 ROC-AUC = 0.9076, recall риска = 0.83, precision риска = 0.45. Для интерпретации факторов риска использована модель Кокса и Hazard Ratio / HR: коэффициент, который показывает, повышает признак риск отчисления или снижает его.
7. Финальный прототип переведен в бизнес-формат “Светофора”: зеленая, желтая и красная зоны риска, приоритеты обработки и рекомендации для тьюторов. На экваторе M3 красная зона составила 211 студентов из 1407; рекомендуемая точка старта активного вмешательства - 14-й день модуля.

2. Соответствие критериям оценивания

Критерий	Что сделано в работе
Интерпретируемость паттернов/ инсайтов	Построены MI, Permutation Importance и Cox Hazard Ratios. Для каждого ключевого фактора дана бизнес-интерпретация: охват уро-

Критерий	Что сделано в работе
	ков, темп относительно группы, выходной режим, паузы, хаотичный рост действий.
Корреляции и гипотезы о причинно-следственных связях	Посчитаны Spearman-корреляции по модулям 1-2, MI для нелинейных связей, HR для направленности влияния. Причинность формулируется как гипотеза, а не как доказанный факт.
Соответствие задаче	Есть прогноз риска и выявление групп риска. RSF показывает C-index 0.7636 на Out-of-Time M2 -> M3. Прототип выделяет 211 студентов красной зоны в M3.
Техническая завершенность прототипа	Собраны воспроизводимые витрины, есть контроль гранулярности, дедупликация, temporal-срезы без утечки данных, сохранены CSV-артефакты.
Наличие прототипа	Реализован “Светофор”: зеленая, желтая и красная зоны, приоритеты и действия для кураторов.
Наглядность результатов	В отчет включены графики корреляций, MI, важности RSF, ROC-кривых, Hazard Ratios и динамики “Светофора”.

3. Постановка задачи

Заказчик: ООО “Цифровое образование” (Цифриум), EdTech-платформа с онлайн-курсами, вебинарами, видео, домашними заданиями, тестами и промежуточной аттестацией.

Бизнес-проблема: низкая доходимость онлайн-курсов. Нужно заранее находить студентов, которые с высокой вероятностью перестанут учиться, и объяснять, какие поведенческие признаки привели к риску.

Конечные пользователи:

- тьюторы: получают список студентов в зоне риска и приоритет действий;
- методисты: видят паттерны, по которым можно менять структуру курса и поддержку;
- аналитики/ML-инженеры: получают витрины и стартовый прототип для дальнейшей модели.

Формальная цель модели: прогнозировать риск неуспешного завершения модуля по LMS-данным, доступным на выбранный момент времени, без использования будущих событий.

4. Подготовка таргета

4.1. Документационная эвристика

Первый подход к предсказанию статуса M3 строился по таблицам `stats__module_*` и документации к критериям перевода. Идея была максимально простая: взять поля из `stats__module`, перевести документированные критерии в набор бинарных правил и получить статус через эвристику без сложной модели.

На M1 и M2 есть фактический `Статус`, поэтому этот подход можно было проверить до применения к M3. Сравнение показало, что документационная эвристика слишком строгая и заметно расходится с фактическим статусом.

Модуль	Строк	Accuracy	Precision	Recall	F1	FP	FN
M1	2972	0.8567	1.0000	0.7821	0.8777	0	426
M2	1955	0.8179	1.0000	0.8006	0.8892	0	356
M1+M2	4927	0.8413	1.0000	0.7909	0.8832	0	782

Интерпретация: полный набор документированных критериев не совпадает с фактическим `Статус` в данных. Поэтому использовать такую эвристику как финальный способ разметки M3 нельзя: она систематически строже реальной логики перевода и дает много ошибок относительно фактического статуса на M1-M2.

4.2. Улучшенная эвристика

На M1 и M2 были проверены простые правила. Лучшим оказалось правило:

`Сдал ПА` (промежуточную аттестацию) `== Да` или `Балл ПА >= 8 -> Completed`, иначе `Dropped`.

Качество улучшенной эвристики:

Модуль	Строк	Accuracy	Precision	Recall	F1	FP	FN
M1	2972	0.9976	0.9964	1.0000	0.9982	7	0
M2	1955	1.0000	1.0000	1.0000	1.0000	0	0

На M3 это правило дает:

Статус по эвристике	Количество
Completed	1707
Dropped	78

Дополнительная проверка траектории: из 78 студентов, помеченных как `Dropped` в M3 по правилу ПА, никто не появляется в M4. Это не доказывает фактический статус M3, но делает эвристику значительно устойчивее, чем полную документационную логику, для которой это правило “отчислен значит не появлялся больше” не работало.

5. Гранулярность и витрины

Основной вывод по гранулярности: моделировать нужно уровень `user-course`, а не просто `user`. Один и тот же пользователь проходит разные модули как разные курсы, поэтому схлопывание до `user_id` смешивает разные этапы обучения и искажает признаки.

По событиям LMS собраны две рабочие витрины.

1. `artefacts/user_course_modeling_base.csv`: общая витрина на 8401 строку и 91 колонку. Одна строка соответствует связке `module + user_id + course_id`. Внутри есть статусы, контекст модуля и агрегаты по действиям, ответам, просмотрам, тренингам и доступам. Эта таблица использо-

валась как базовый слой для анализа и моделей на уровне студента в конкретном модуле.

2. `artefacts/user_course_modeling_snapshots_long.csv`: temporal-витрина на 33604 строки. Единица наблюдения та же, но каждая строка развернута в один из временных срезов: `7_days`, `14_days`, `21_days` или `midpoint`. В каждый срез попадают только события до даты отсечения, поэтому модель не видит будущую активность и не получает утечку данных.

6. Корреляции и аналитические инсайты

6.1. Spearman-корреляции на M1-M2

Корреляционный анализ считался на сводных таблицах `stats__module_*`, а не на сырых LMS-событиях. В расчет брались только M1 и M2, потому что только там есть фактический `Статус`. Использован Spearman, так как признаки смешанные: бинарные и числовые, а зависимость не обязана быть линейной.

Эти связи частично ожидаемы: ПА, обязательные задания и контроль входят в логику перевода. Поэтому для раннего прогноза такие итоговые признаки нельзя использовать как признаки модели, если они еще не были известны на момент прогноза. Их ценность в другом: они показывают, что фактический `Статус` в данных сильнее всего связан с прохождением ПА и практическими критериями, а не с демографией или техническими ID.

Отдельно интересно, что `pa_score` почти не связан с прохождением курса. Это объясняется структурой данных: на всю выборку есть ровно 1 пользователь, который сдавал ПА, но не набрал нужное число баллов. Остальные отчисленные студенты ПА вообще не сдавали. Поэтому сам балл ПА почти ничего не добавляет: важен факт сдачи ПА, а не величина балла среди сдавших.

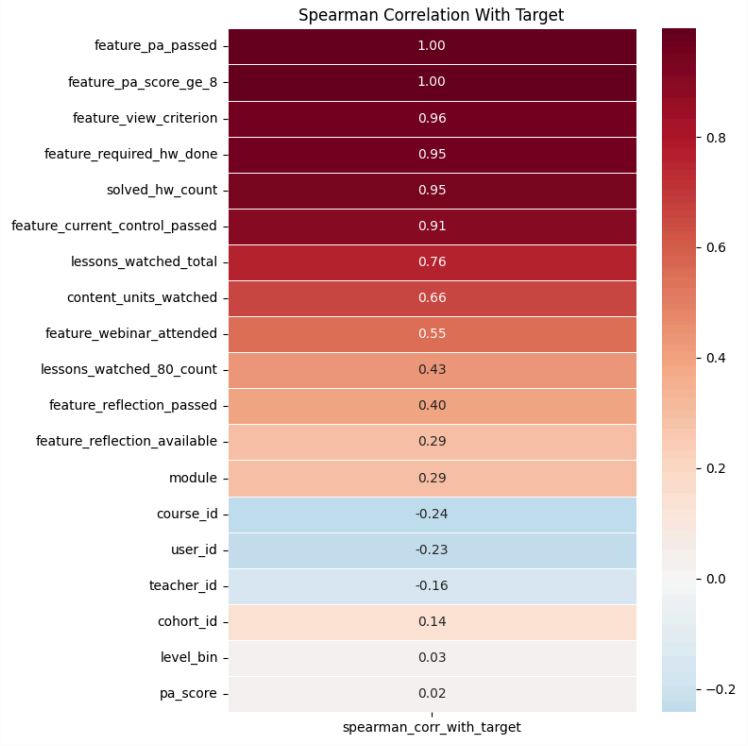

Скриншот 1. Spearman-корреляции признаков с фактическим target

6.2. Mutual Information

Здесь мы перешли от сводных `stats__module_*` к признакам из сырых событий LMS: кликам, ответам, просмотрам, тренировкам, паузам и динамике активности. На срезе `midpoint` рассчитана Mutual Information по 78 числовым признакам. MI полезна тем, что ловит нелинейные связи и не ограничивается линейной корреляцией.

Ключевые выводы:

- нормированные признаки относительно когорты важнее абсолютных значений;
- сильны сигналы темпа: `Velocity_W2_zscore`, дни с последнего действия, максимум дневных кликов;
- важен охват практики: `answer_tasks_nunique_zscore`;
- важны media-признаки: максимальная доля просмотра и число 80% media-сессий.

Бизнес-интерпретация: риск нужно искать не только по “мало/много сделал”, а по отклонению от нормального ритма конкретного курса. Один и тот же абсолютный уровень активности может быть нормой в одной когорте и тревожным сигналом в другой.

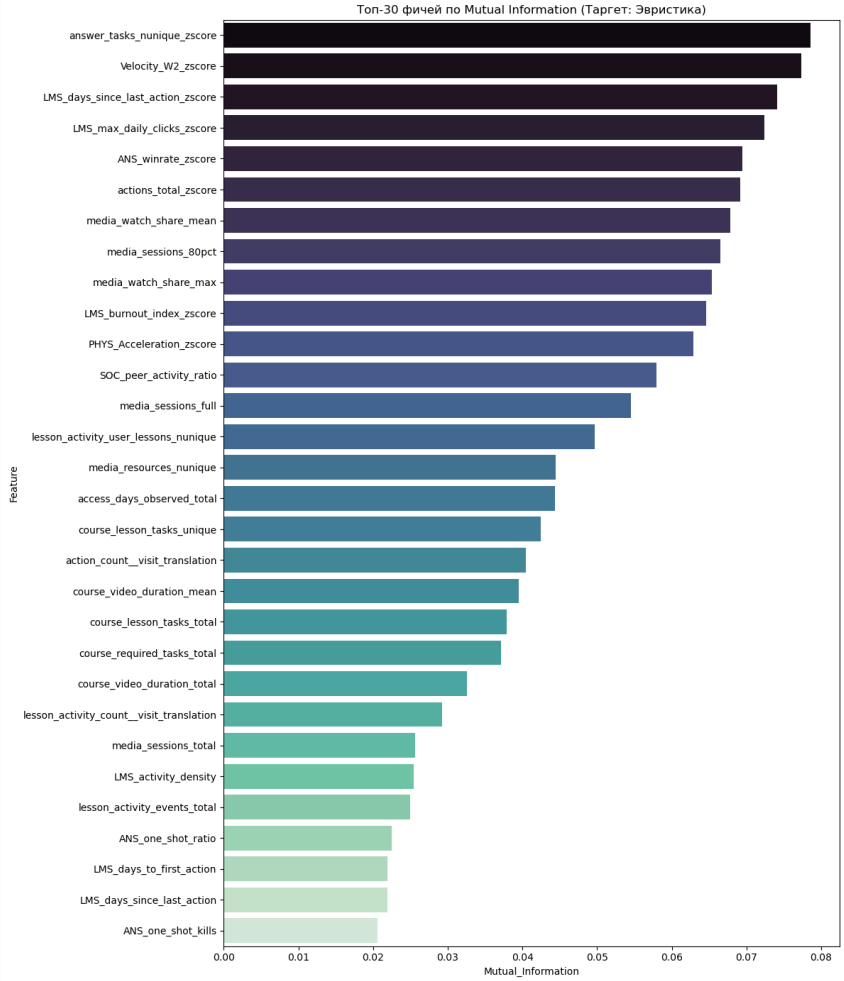

Скриншот 2. Топ-30 признаков по Mutual Information

6.3. Гипотезы о причинно-следственных механизмах

Ниже именно гипотезы, а не доказанная причинность. Наблюдательные LMS-данные показывают устойчивые ассоциации, но не дают полного контроля за внешними факторами: мотивация, расписание, качество преподавания, сложность конкретной темы, внешняя нагрузка студента.

Наблюдение	Возможный механизм	Как проверять дальше
Высокий `LMS_days_since_last_action_zscore` повышает риск	Длинная пауза относительно когорты означает потерю учебного ритма	A/B: мягкий контакт после 3-5 дней аномальной тишины

Наблюдение	Возможный механизм	Как проверять дальше
Высокий `LMS_ratio_weekend` повышает риск	Учеба только на выходных похожа на накопление долга и повышает вероятность срыва	Проверить эффект недельных микро-дедлайнов и weekday-напоминаний
Высокий `actions_total_zscore` повышает риск	Всплеск кликов может означать не продуктивность, а хаотичный поиск, попытку догнать, проблемы с навигацией	Добавить события “ошибки”, “повторные открытия”, время между действиями
Высокий `SOC_peer_activity_ratio` снижает риск	Студент, идущий в темпе группы, получает больше контекста и меньше копит отставание	Сравнить интервенции для студентов, отстающих от медианы группы
Широкий охват уроков снижает риск	Студент движется по программе последовательно и не застревает на узком участке	Добавить карту сложных тем и прогресс по конкретным урокам

7. Модели и метрики

7.1. Random Survival Forest и Permutation Importance

Для survival-подхода выбрана Random Survival Forest (RSF). Причины:

- работает с временем до события, а не только с бинарным исходом;
- дает risk score (балл риска) для ранжирования студентов;
- строит кривые выживаемости;
- улавливает нелинейные зависимости между поведением и риском.

Топ-15 признаков RSF:

1. `lesson_activity_user_lessons_nunique` — importance 0.0347. Число уникальных уроков, где была активность студента; показывает ширину охвата курса.
2. `SOC_peer_activity_ratio` — importance 0.0325. Активность студента относительно среднего темпа группы.
3. `LMS_ratio_weekend` — importance 0.0289. Доля активности, пришедшаяся на выходные.
4. `LMS_days_since_last_action_zscore` — importance 0.0213. Насколько пауза с последнего действия выше или ниже типичной паузы в группе.
5. `LMS_days_since_last_action` — importance 0.0180. Число дней с последнего действия студента в LMS.
6. `LMS_weekend_clicks` — importance 0.0163. Число действий в LMS по выходным.
7. `action_count__visit_translation` — importance 0.0145. Число событий посещения трансляций в общем логе действий.
8. `lesson_activity_count__visit_translation` — importance 0.0131. Число событий посещения трансляций в логе активности по урокам.
9. `ANS_one_shot_kills` — importance 0.0114. Число задач, решенных с первой попытки.
10. `LMS_max_daily_clicks_zscore` — importance 0.0102. Насколько максимальное число действий за день отличается от типичного значения в группе.
11. `LMS_burnout_index_zscore` — importance 0.0093. Нормированный индекс перегрузки по паттернам активности.
12. `ANS_winrate_zscore` — importance 0.0074. Насколько доля успешных ответов отличается от типичной доли в группе.
13. `LMS_max_daily_clicks` — importance 0.0072. Максимальное число действий студента за один день.
14. `lesson_activity_count__show_conspect` — importance 0.0067. Число открытий конспекта.
15. `actions_total` — importance 0.0067. Общее число действий студента в LMS на выбранном срезе.

Метрика RSF: C-index = 0.7662 ± 0.0242.

C-index показывает, насколько хорошо survival-модель ранжирует пары студентов по риску: у кого событие отчисления должно наступить раньше. Значение 0.5 соответствует случайному ранжированию. Значение около 0.76 на таких данных означает полезную прогностическую силу.

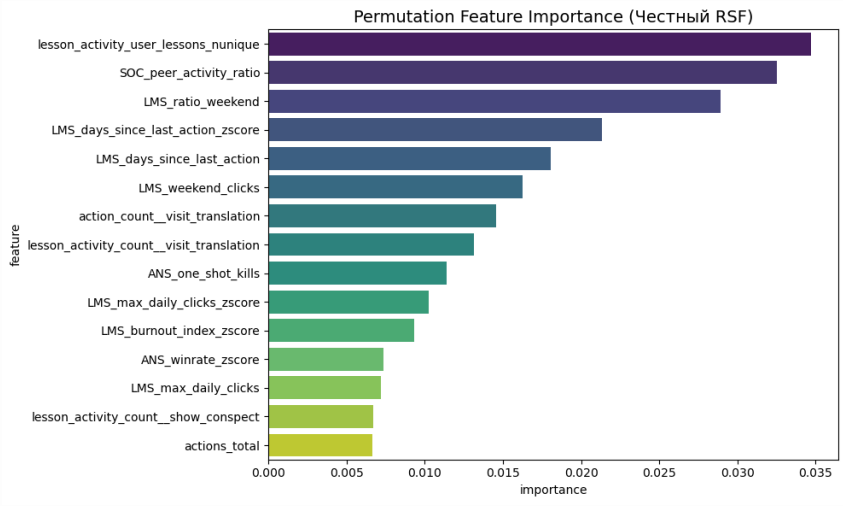

Скриншот 3. Permutation Importance для RSF

7.2. Out-of-Time проверка M2 -> M3

Самая важная проверка: модель обучалась на M2 и тестировалась на M3, где таргет был получен улучшенной эвристикой из п. 4.2, потому что фактического статуса M3 в данных нет. Это ближе к реальному использованию, где модель обучена на завершенном потоке и применяется к следующему.

Показатель	Значение
Train	M2
Test	M3
Обучающая выборка	1479 студентов
Тестовая выборка	1407 студентов
C-index на train M2	0.9576
C-index на test M3	0.7636

Интерпретация: падение с train до test ожидаемо, но итоговый C-index 0.7636 существенно выше случайного уровня. Это означает, что поведенческие признаки переносятся между соседними учебными периодами.

7.3. Сравнение классификационных подходов

Для бизнес-порога прототипа дополнительно сравнивались классификационные модели на срезе M3 midpoint:

- модель 1: обучение на M1+M2;
- модель 2: обучение только на M2.

Модель	AUC на M3	Accuracy при пороге 0.90	Recall риска	Precision риска
M1+M2	0.7020	0.23	0.95	0.04
Only M2	0.7416	0.75	0.59	0.07

Вывод: M1+M2 дает слишком много ложных алертов. Для оперативного “Светофора” лучше использовать последний завершенный модуль, потому что он ближе к текущему контексту.

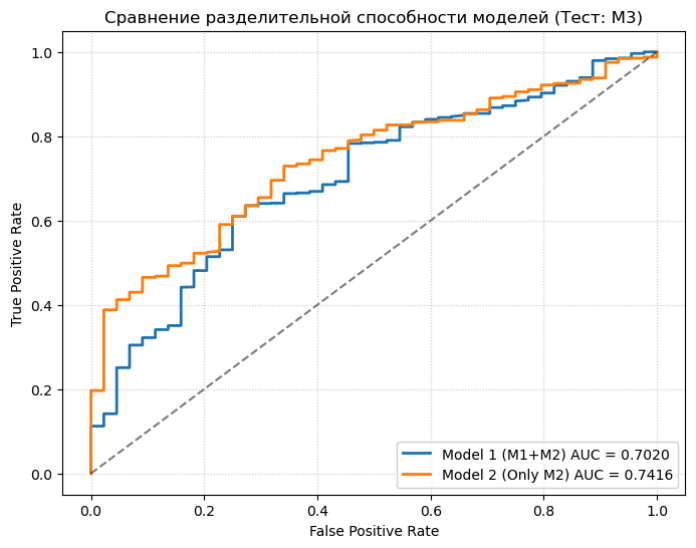

Скриншот 4. ROC-сравнение M1+M2 и Only M2 на M3

7.4. Внутренняя проверка M1+M2

Внутренняя проверка показывает верхнюю границу качества при случайном разбиении внутри M1+M2 и использовании фактического таргета.

Показатель	Значение
Размер выборки	3571 строка

Показатель	Значение
Число признаков	79
Разбиение	80/20, stratified
ROC-AUC	0.9076
Accuracy	0.83
Precision риска	0.45
Recall риска	0.83
F1 риска	0.59

Эта метрика выше OOT-проверки, потому что train/test ближе по распределению. Поэтому как основную оценку переносимости следует считать OOT C-index, а внутреннюю проверку использовать как оценку потенциала признаков.

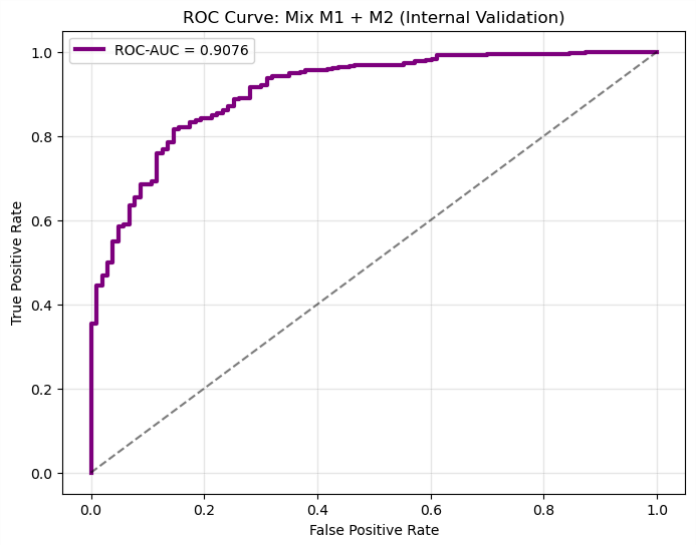

Скриншот 5. ROC-AUC на внутренней проверке M1+M2

8. Интерпретация риска через Cox Hazard Ratios

Random Survival Forest дает сильное ранжирование, но сложен для прямого объяснения. Поэтому дополнительно обучена модель Кокса на отобранных признаках. Она показывает Hazard Ratio: во сколько раз меняется риск при увеличении признака на 1 стандартное отклонение.

Правило чтения:

- HR > 1: признак повышает риск;
- HR < 1: признак снижает риск;
- HR около 1: нейтральный эффект.

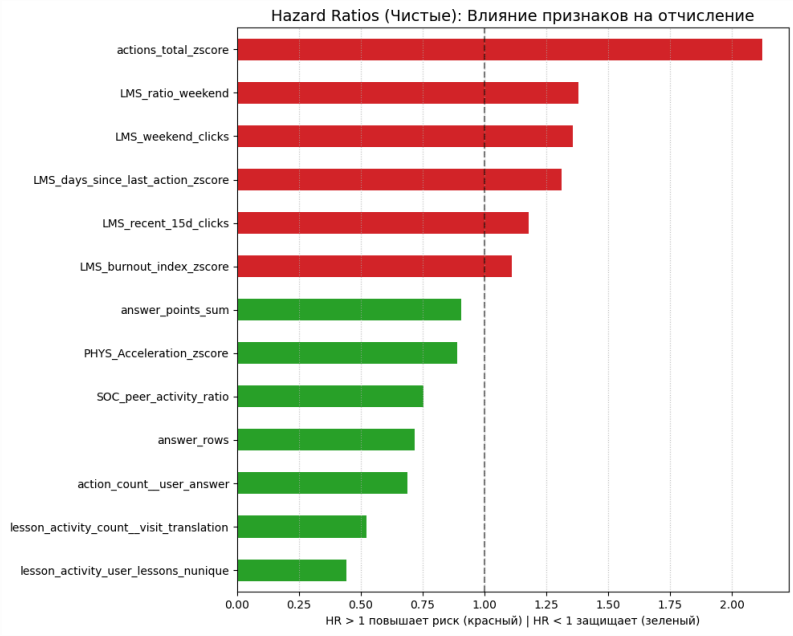

Скриншот 6. Cox Hazard Ratios

Практический вывод для тьютора:

1. Сначала проверять студентов с высоким `actions_total_zscore`: это может быть академический стресс, попытки догнать курс или проблема с навигацией.
2. Отдельно контролировать студентов, которые учатся почти только на выходных.
3. Быстро возвращать в ритм студентов с растущей паузой с последнего действия.
4. Не вмешиваться избыточно в зеленую зону: широкий охват уроков и темп на уровне группы уже являются сильной защитой.

9. Прототип “Светофор”

9.1. Логика сегментации

Прототип переводит risk score модели в операционные зоны:

- зеленая зона: 60% студентов с минимальным риском;
- желтая зона: следующие 25%, профилактическое внимание;

- красная зона: верхние 15% риска, приоритетная ручная работа.

Такое квантильное правило удобно для планирования ресурсов: доля красной зоны фиксирована, тьюторы заранее понимают размер очереди.

9.2. Результаты на M3, midpoint

В оперативную выборку M3 на экваторе вошло 1407 студентов.

Зона	Студентов	Доля	Средний risk score	Средняя вероятность активности к 30-му дню	Приоритет
Зеленая	844	60.0%	0.242	0.9856	Низкий
Желтая	352	25.0%	1.605	0.9175	Средний
Красная	211	15.0%	4.184	0.8214	Высокий

Интерпретация:

- зеленая зона почти не теряет активность по кривой выживаемости;
- желтая зона начинает проседать после 10-го дня и требует профилактики;
- красная зона показывает резкое снижение уже на ранних днях, поэтому это основной список для тьюторов.

Бизнес-эффект: вместо ручной проверки 1407 студентов куратор получает 211 студентов высшего приоритета. Это сокращает фронт первичной ручной работы до 15% потока.

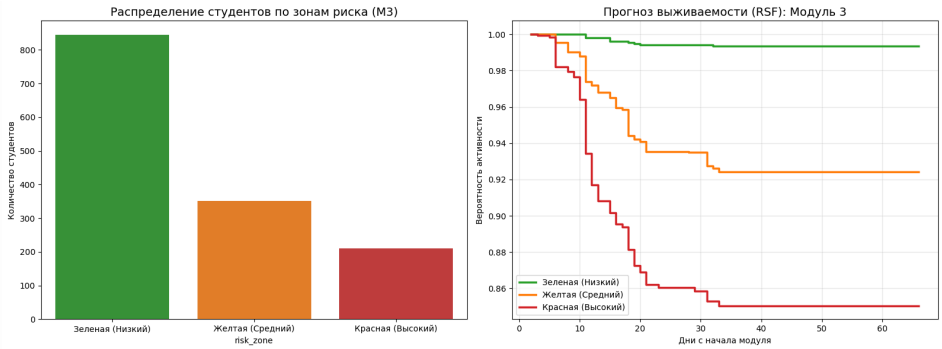

Скриншот 7. Распределение M3 по зонам риска и кривые выживаемости

9.3. Рекомендуемые действия

Зона	Цель	Действие
Красная	Удержать студента до точки невозврата	Личный контакт, выяснение причины паузы, помощь с навигацией, корректировка учебного плана
Желтая	Не допустить перехода в красную зону	Smart nudging, напоминание о прогрессе, подборка материалов, поддерживающий вебинар
Зеленая	Не перегружать лишним вниманием	Self-service, стандартные коммуникации, мониторинг без ручного вмешательства

10. Динамический мониторинг

“Светофор” был проверен не только на экваторе, но и на срезах 7, 14 и 21 день.

Срез	Зеленая	Желтая	Красная	Всего	Средняя P30 зеленой	Средняя P30 желтой	Средняя P30 красной
7 дней	485	201	122	808	0.9773	0.9405	0.8745
14 дней	706	294	177	1177	0.9868	0.9530	0.8893
21 день	833	348	208	1389	0.9841	0.9184	0.8285
midpoint	844	352	211	1407	0.9856	0.9175	0.8214

Главный вывод: деление на зоны уже работает с 7-го дня, но оптимальная точка для активного вмешательства - 14-й день.

Почему 14-й день:

- в мониторинге уже 1177 студентов, это 83% финальной активной midpoint-популяции;
- красная зона уже сформирована: 177 студентов;
- до резкого падения вероятности в красной зоне на 21-й день еще есть около недели;
- нагрузка на тьюторов уже прогнозируема.

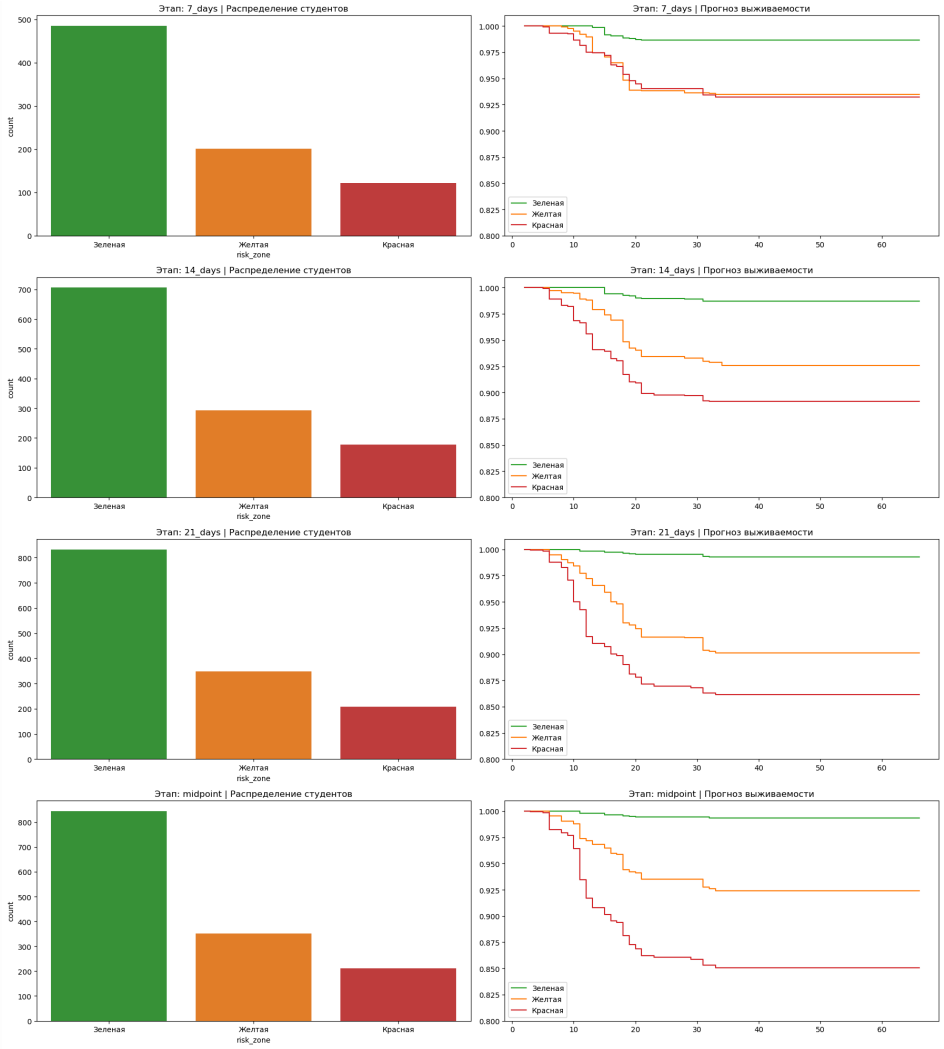

Скриншот 8. Динамика зон риска на 7, 14, 21 день и midpoint

11. Что именно считать инсайтами для методистов

11.1. Не только низкая активность, но и неправильная активность

Данные показывают, что риск связан не только с отсутствием действий. Аномально высокий всплеск кликов (`actions_total_zscore`) тоже повышает риск. Это может означать:

- студент накопил долг и пытается быстро догнать;
- студент хаотично ищет нужный материал;
- студент часто возвращается к одним и тем же местам;

- интерфейс или тема курса вызывают затруднение.

Методистам стоит смотреть не только на “мало активен”, но и на “слишком резко активировался”.

11.2. Ритм важнее абсолютного числа действий

`SOC_peer_activity_ratio`, z-score признаков и velocity-признаки показывают, что студент оценивается относительно текущей когорты. Это важно: разные группы и модули имеют разные темпы. Универсальный абсолютный порог кликов может быть грубым.

11.3. Выходной режим как риск

Высокий `LMS_ratio_weekend` связан с риском. Возможный механизм: студент учится нерегулярно, копит долг и пытается закрыть его за два дня. Для профилактики можно использовать:

- небольшие weekday-напоминания;
- короткие промежуточные цели;
- подсветку недельного прогресса;
- ранний контакт при повторяющемся выходном паттерне.

11.4. Широкий охват уроков лучше, чем отдельные попытки

Самый сильный защитный фактор по HR - `lesson_activity_user_lessons_nunique`. Это означает, что успешный студент движется по программе шире и последовательнее. Если студент много кликает, но затрагивает мало уникальных уроков, это отдельный сигнал застревания.

12. Ограничения

1. M3 не имеет фактического `Статус`, поэтому часть анализа M3 опирается на эвристику. Она проверена косвенно через отсутствие возврата “Отчисленных” студентов в M4, но это не заменяет фактическую метку.
2. Наблюдательные LMS-данные не доказывают причинность. В отчете причинные связи формулируются как гипотезы для проверки.
3. В модели пока не хватает внешнего контекста: расписание школьника, сложность конкретной темы, качество вебинара, коммуникации тьютора, прошлый опыт студента.
4. Для ранних срезов часть признаков имеет меньше покрытия. Это нормальное свойство temporal-прогноза, но его нужно учитывать при калибровке.
5. Вероятности survival-модели нужно дополнительно калибровать, если использовать их как точные бизнес-вероятности отчисления.

13. Рекомендации по развитию

13.1. Longitudinal-обучение

Сейчас ключевая модель обучалась на срезе midpoint. Следующий шаг: обучать модель на всех временных точках сразу и добавить `days_passed` как контекст. Это позволит точнее сравнивать риск на 7, 14, 21 день и на экваторе.

Важно: при train/test split, то есть при разбиении на обучение и проверку, нужно группировать по студенту или user-course, чтобы разные snapshot-срезы одного объекта не попали одновременно в train и test.

13.2. Калибровка вероятностей

Нужно откалибровать risk score и survival probability, то есть балл риска и вероятность оставаться активным, чтобы вероятность 0.85 означала ожидаемые 85 успешных завершений из 100 похожих студентов. Это упростит планирование ресурсов и оценку эффекта интервенций.

13.3. Интерфейс для тьютора

Выгрузка для тьютора должна содержать:

- `user_id`;
- модуль и курс;
- зона риска;
- risk score;
- вероятность активности к 30-му дню;
- топ-3 причины риска для конкретного студента;
- рекомендуемое действие.

Минимальный формат:

Поле	Зачем нужно
`risk_zone`	Приоритет обработки
`risk_score`	Сортировка внутри зоны
`survival_prob_d30`	Оценка срочности
`top_risk_factor_1..3`	Объяснение для тьютора
`recommended_action`	Быстрое действие без ручной интерпретации модели

13.4. Внешние признаки

Рекомендуемые источники для обогащения:

- сложность темы и урока;
- даты дедлайнов;
- факт коммуникации тьютора;
- посещаемость вне LMS;
- история предыдущих модулей и прошлых попыток;
- технические проблемы: ошибки запуска видео, зависания, повторные открытия одного материала.

14. Артефакты работы

Арте-факт	Путь	Назначе
Основной ноутбук	Tri_sigma_final_research.ipynb	Сбор витри признаки,

Арте-факт	Путь	Назначе
		ли, метрик “Светофор
Грану-лярность	modules/granularity_selection.ipynb	Доказателі выбора ур user-cours
Эвристи-ка статуса	modules/heuristics_status_deducing.ipynb	Очистка stats__mod выбор при женного та
Единый статус-ный датасет	modules/status_modules_complete.csv	Population-лица по 4 модулям
Базовая витрина	artefacts/user_course_modeling_base.csv	Полная us course вит
Temporal-витрина	artefacts/user_course_modeling_snapshots_long.csv	Snapshot-в на 7/14/21/mi
Скрин-шоты отчета	report_assets/	Графики д Markdown/

15. Финальный вывод

Работа закрывает поставленную задачу: построен технически завершенный прототип прогнозирования риска на LMS-данных, собраны витрины, проведены корреляционный и нелинейный анализы, отобраны интерпретируемые признаки, рассчитаны метрики и сформирован бизнес-прототип “Светофор”.

Основная ценность для заказчика: модель не только ранжирует студентов по риску, но и объясняет, почему студент попал в риск. Это переводит ML-результат из “черного списка вероятностей” в рабочий инструмент тьютора: кого обработать первым, когда начать контакт и какой вопрос задать студенту.